Projeto Integrador Avançado: IA e Análise de Dados em Sistemas Industriais

Empresa Fictícia: AeroMotion Dynamics S.A. (Divisão de Turbinas & Propulsão de Alta Precisão)
Disciplina / Módulo: Inteligência Artificial e Ferramentas para Análise de Dados em Sistemas Industriais

1. Contextualização e Objetivos Gerais

A **AeroMotion Dynamics S.A.** é uma produtora global de sistemas propulsores e turbinas industriais de alta precisão. Recentemente, a empresa concluiu a instrumentação de suas quatro principais bancadas de testes de desenvolvimento (equipamentos TURB-101 a TURB-104) com uma malha densa de sensores IoT de alta frequência. As bancadas coletam parâmetros críticos de operação a cada 10 minutos, gerando volumes expressivos de dados de telemetria.
Entretanto, a fábrica enfrenta desafios complexos que comprometem a eficiência operacional e a garantia de qualidade:

- **Modos de Falha Múltiplos e Interconectados:** As avarias em turbinas industriais não ocorrem de forma binária simples. Elas manifestam-se em diferentes assinaturas físicas, como desgaste progressivo de rolamentos, desbalanceamento aerodinâmico/mecânico de rotores e eventos severos de cavitação combinada com superaquecimento.
- **Ruído Sensor e Interferência Eletromagnética:** O ambiente fabril gera ruídos impulsivos, perdas temporárias de pacotes e flutuações de sinal que mascaram a degradação real do maquinário.
- **Garantia Multimodal de Qualidade:** Além do monitoramento por sensores, a montagem das turbinas necessita de inspeção visual automatizada em tempo real para validar geometrias de pás e identificar zonas térmicas críticas durante testes funcionais.

O objetivo deste Projeto Integrador é capacitar os estudantes a planejar, desenvolver e implantar uma solução de Inteligência Artificial de ponta a ponta (End-to-End MLOps & Visão Computacional) para antecipar falhas industriais e automatizar inspeções técnicas de alta complexidade.

2. Matriz de Ferramentas e Tecnologias Utilizadas

Abaixo apresenta-se o ecossistema tecnológico adotado ao longo do projeto:

Categoria	Ferramentas / Bibliotecas	Aplicação no Projeto
Linguagem e Ambiente	Python 3.10+, Jupyter Notebook, VS Code	Desenvolvimento do pipeline de dados, prototipagem e scripts da API.
Engenharia de Dados	Pandas, NumPy, SciPy	Limpeza, interpolação temporal, Z-score, e criação de *rolling features*.
Visualização & EDA	Matplotlib, Seaborn	Análise exploratória, matrizes de correlação e gráficos de séries temporais.
Machine Learning	Scikit-Learn, XGBoost, LightGBM, Imbalanced-Learn (SMOTE)	Modelagem multiclasse, balanceamento de classes e detecção de anomalias (Isolation Forest).
Visão Computacional	OpenCV, NumPy	Detecção de bordas (Canny), análise de contornos e segmentação de espaço térmico HSV.
Engenharia de Software & Deploy	FastAPI, Pydantic, Uvicorn, Docker, Docker-Compose	Criação do microserviço RESTful assíncrono e conteinerização para Edge Computing.

3. Detalhamento das Etapas do Projeto Integrador

Etapa 1: Diagnóstico, Saneamento e Feature Engineering em Séries Temporais Industriais (26h)

Cenário: Os alunos recebem o dataset bruto dados_sensores_aeromotion.csv composto por 12.000 registros contendo leituras de temperatura, vibração RMS, pressão de óleo, rotação (RPM), emissão acústica e corrente elétrica em 4 bancadas de testes.

Atividades Requeridas:

1. **Inspeção Estrutural:** Identificar tipos de dados, verificar consistência de

timestamps (intervalos de 10 min) e quantificar a taxa de ausência de dados agrupada por equipamento (id_equipamento).

2. **Tratamento Avançado de Ausentes e Outliers:**
    - Aplicar interpolação temporal linear ou spline por equipamento para preencher falhas pontuais (NaN), respeitando a física do processo contínuo.
    - Identificar e tratar anomalias extremas provocadas por interferência eletromagnética (ex: temperaturas de 999.9°C e vibrações negativas de -99.0 mm/s) utilizando o Z-Score móvel ou limites operacionais físicos.
    -
3. **Engenharia de Features Temporais (Feature Engineering):**
    - Calcular médias móveis (*Rolling Mean*) e desvios padrões móveis (*Rolling Std*) com janelas de 1h e 6h para vibração e temperatura.
    - Criar a feature derivada "Severidade Dinâmica" definida pela razão entre Vibração RMS e Rotação (RPM).

4. **Análise Exploratória Multivariada (EDA):**
    - Gerar matriz de correlação cruzada e gráficos de par (*pairplots*).
    - Analisar o comportamento das variáveis sob os três regimes operacionais (Carga_Alta, Carga_Media, Cruzeiro).

Entregáveis da Etapa 1: Notebook Jupyter rigorosamente comentado e Relatório Técnico em PDF detalhando as decisões de pré-processamento de dados e os achados da análise exploratória.

Etapa 2: Inteligência Preditiva Multiclasse, Detecção de Anomalias e MLOps

Cenário: A equipe de manutenção preventiva precisa diagnosticar precocemente a falha específica para direcionar os técnicos com as peças de reposição corretas antes da paralisação total da bancada.

Atividades Requeridas:

1. **Preparação de Dados e Lidar com Desbalanceamento:**
    - Dividir temporalmente o dataset em Treino (70%) e Teste (30%).
    - Aplicar técnica de reamostragem (**SMOTE**) ou ajuste de pesos de classe (**class_weight='balanced'**), considerando que apenas ~12% das amostras representam falhas reais.
    - Padronizar os dados utilizando RobustScaler ou StandardScaler.

2. **Modelagem Multiclasse Supervisionada:**

    - Treinar e comparar dois modelos de classificação multiclasse (ex: *Random Forest* vs. *XGBoost / LightGBM*) para prever os 4 estados target: 0 (Normal), 1 (Desgaste_Rolamento), 2 (Desbalanceamento_Rotor) e 3 (Cavitacao_Superaquecimento).
    - Ajustar hiperparâmetros por meio de busca em grade (*GridSearchCV*) ou amostragem aleatória (*RandomizedSearchCV*).

3. **Detecção Não Supervisionada de Anomalias:**

    - Treinar um modelo de **Isolation Forest** exclusivamente com dados operacionais normais para identificar comportamentos anômalos não documentados previamente.

4. **Avaliação e Explicabilidade:**

    - Construir a Matriz de Confusão Multiclasse (4x4) e calcular Acurácia, Precisão, Recall e F1-Score (Macro e Weighted). Dar foco prioritário ao **Recall por classe de falha**.
    - Analisar a relevância de variáveis (*Feature Importance* ou valores SHAP) para interpretar fisicamente as previsões.

5. **Plano de MLOps e Monitoramento:**

    - Exportar o modelo e o escalador treinados (.joblib ou .pkl).
    - Elaborar um plano de monitoramento contínuo prevendo estratégias contra *Data Drift* (desvio do padrão dos sensores) e *Concept Drift* em uma janela operacional de 12 meses.

Entregáveis da Etapa 2: Scripts de treinamento e validação, arquivos de modelo exportados, tabela comparativa de desempenho e documento sintético do plano de MLOps.

Etapa 3: Visão Computacional, Microsserviço RESTful em Docker e Governança Regulatória (28h)

Cenário: Integração do sistema preditivo à infraestrutura de automação industrial (CLP/SCADA) via API e implementação de inspeção óptica/térmica em tempo real na montagem de pás de turbina.

Atividades Requeridas:

1. **Visão Computacional Multimodal (OpenCV):**
    - **Inspeção Geométrica:** Aplicar filtros de suavização, conversão para escala de cinza e o algoritmo *Canny Edge Detection* para extrair contornos e validar circularidade e dimensionalidade de componentes.
    - **Inspeção Térmica:** Processar imagens infravermelhas convertendo-as para o espaço de cor **HSV** e aplicando limiarização (thresholding) para delimitar "hotspots" (zonas de superaquecimento em graus críticos).
2. **Desenvolvimento da API RESTful (FastAPI):**
    - Desenvolver uma API com suporte a Pydantic para validação de dados de entrada.
    - Implementar endpoints: POST /predict (inferência em tempo real para 1 leitura), POST /predict-batch (inferência em lote) e GET /health (status do serviço e versão do modelo).
3. **Conteinerização (Docker):**
    - Escrever um Dockerfile otimizado (multistage build se necessário) e um arquivo docker-compose.yml para implantar o serviço de inferência em nós de Edge Computing.
4. **Parecer Técnico, Regulatório e Ético:**
    - Redigir parecer técnico de 3 a 4 páginas abordando:
        1. Impactos trabalhistas e requalificação profissional de inspetores manuais.
        2. Conformidade com a LGPD referente ao uso de câmeras no chão de fábrica (mascaramento de rostos de operadores).
        3. Classificação do sistema sob o *EU AI Act* / Regulamentações de IA de Alto Risco.
        4. Cibersegurança Industrial (proteção contra envenenamento de dados e ataques à rede OT/IT).

Entregáveis da Etapa 3: Código fonte do pipeline de Visão Computacional, aplicação FastAPI devidamente testada, arquivos Docker funcionais e Parecer Técnico/Ético consolidado em PDF.

4. Dicionário de Dados do Dataset Industriais (dados_sensores_aeromotion.csv)

Coluna	Tipo de Dado	Unidade	Descrição e Faixa Operacional
timestamp	Datetime	AAAA-MM-DD HH:MM	Data e hora da amostragem (intervalo de 10 min).
id_equipamento	Categorias (String)	-	Identificador da bancada de teste (TURB-101 a TURB-104).
modo_operacao	Categorias (String)	-	Regime de carga: Cruzeiro, Carga_Media, Carga_Alta.
horas_operacao_acumuladas	Float	Horas (h)	Tempo acumulado de funcionamento do motor (100.0 h a 4500.0 h).
temperatura_mancal_c	Float	Graus Celsius (°C)	Temperatura do mancal principal (Faixa normal: 45°C a 85°C). Contém ruídos (999.9°C) e NaNs.
vibracao_rms_mms	Float	mm/s RMS	Nível de vibração global do eixo (Faixa normal: 1.0 a 4.5 mm/s). Contém ruídos (-99.0 mm/s) e NaNs.
pressao_oleo_bar	Float	Bar	Pressão do sistema de lubrificação (Faixa normal: 3.5 a 5.2 Bar). Contém NaNs.

Coluna	Tipo de Dado	Unidade	Descrição e Faixa Operacional
rotacao_rpm	Float	RPM	Velocidade angular do rotor (Faixa normal: 2300 a 3600 RPM).
emissao_acustica_db	Float	Decibéis (dB)	Ruído ultrassônico de fricção mecânica (Faixa normal: 40 a 68 dB). Contém NaNs.
corrente_eletrica_amp	Float	Amperes (A)	Corrente consumida pelo sistema de acionamento (Faixa normal: 18 a 42 A).
tipo_falha	Integer (Target)	Código Categórico	0 = Normal 1 = Desgaste de Rolamento 2 = Desbalanceamento de Rotor 3 = Cavitação / Superaquecimento

5. Rubrica de Avaliação Acadêmica

Critério de Avaliação	Peso	Descrição do Desempenho Excelente (Nota Máxima)
Qualidade do Saneamento e Feature Engineering	20%	Tratamento rigoroso de outliers e ausentes respeitando a continuidade temporal das bancadas. Criação de

Critério de Avaliação	Peso	Descrição do Desempenho Excelente (Nota Máxima)
		variáveis móveis e indicadores físicos altamente correlacionados com os modos de falha.
Desempenho dos Modelos Preditivos	25%	Aplica estratégias eficazes para desbalanceamento de classes, obtendo Recall elevado (> 90%) na detecção de todas as classes de falha, com comparação sólida entre modelos.
Qualidade e Precisão na Visão Computacional	20%	Filtros, contornos e segmentação de cor (HSV) parametrizados com precisão, separando com sucesso peças perfeitas de peças com defeitos geométricos e térmicos.
Engenharia de Software e Dockerização	20%	API FastAPI assíncrona, robusta, estruturada com schemas Pydantic, totalmente funcional em lote e tempo real, envelopada em container Docker pronto para uso.
Rigor no Parecer Ético e MLOps	15%	Análise aprofundada sobre governança de IA, LGPD, cibersegurança OT/IT e plano consistente de MLOps para detecção de Data/Concept Drift ao longo do tempo.

Observação Final: Todos os entregáveis em código devem seguir boas práticas de programação (PEP 8, modularização, comentários claros e documentação OpenAPI/Swagger gerada automaticamente pelo FastAPI).